

## 《脑认知与智能计算》小组报告



组 序 第二组

学 号 1851804、1853047、1851195

姓 名 苗成林、孔庆晨、高琪婷

授课老师 孙查如

## 目录

一、	背景简介 .....	3
二、	欧几里得三维空间中几何代数 .....	4
三、	GAN 网络结构 .....	5
四、	GAGAN 模型 .....	7
3.1	总体实验架构 .....	7
3.2	生成损坏数据集 .....	7
(1)	数据归一化 .....	7
(2)	构造交通参数时空矩阵 .....	8
(3)	模拟对交通速度数据的破坏 .....	8
3.3	GAGAN 模型 .....	8
(1)	生成器结构 .....	9
(2)	几何代数卷积神经网络 (GACNN) .....	9
(3)	卷积块注意模块 (CBAM) .....	11
(4)	鉴别器结构 .....	12
(5)	损失函数 .....	12
五、	GAGAN 模型实验结果 .....	13
5.1	数据集 .....	13
5.2	实验设置 .....	13
5.3	实验结果及分析 .....	14
(1)	GAGAN 模型修复结果与与地面实况对比 .....	14
(2)	GAGAN 模型修复结果与其他模型对比 .....	16
六、	结论 .....	17
	参考文献 .....	18

装

订

线

## 使用基于几何代数的生成对抗网络进行交通数据恢复

**摘要:** 交通数据恢复在交通预测、拥堵判断、路网规划等领域发挥着重要作用,完整准确的交通数据有助于更高效、更有效地发现数据中包含的规律。然而,交通数据常有缺失,现有的方法在处理大量交通数据丢失的情况下仍然存在问题。几何代数作为向量代数的推广,对高维数据具有更强大的表示和处理能力。本次课程报告将基于几何代数的生成对抗网络进行探究分析,并对结果进行复现。通过学习多维交通参数的相关性来修复丢失的交通数据。生成器模型由几何代数卷积模块、注意力模块和反卷积模块组成,同时应用全局和局部数据均方误差来形成生成器的损失函数。鉴别器由一个多通道卷积神经网络组成,可以不断优化对抗训练过程。最后,用于验证的数据集来自两条高架公路的真实交通数据。

**关键词:** 交通数据恢复; 几何代数; 深度学习; 智能交通系统; 生成式对抗网络

### 一、背景简介

交通数据对于智能交通系统(ITS)具有重要意义,它为交通流预测、拥堵判断和城市交通网络规划提供了很多有用的信息。准确的交通信息可以使得基于交通数据的分析结果更加可靠,在大型交通流量监测系统中,部署在不同位置的传感器可以收集大量有用的时间序列数据。

然而,由于硬件设备本身的影响,传感器经常无法工作,导致数据收集不完整[1]。同时,在存储大量交通数据的过程中发生的事故,也会造成这些交通数据的缺失。为了修复缺失的交通数据,研究人员尝试了多种方法,包括基于回归模型的方法、基于概率模型的方法和基于深度学习的方法。

基于回归模型的方法主要通过已知数据点评估缺失数据的数学期望。当少量流量数据丢失时,基于局部二值模式(LBP)的支持向量机(SVM)[2]显示出较好的恢复结果。Zhang和Liu[3]提出的最小二乘支持向量机(LS-SVMs)和Tak[4]提出的基于时空相关性的K值邻近算法,在缺失类型和数据时也表现出更好的插补性能。Manoel[5]提出的在线支持向量机(OLSVR)对重复的交通数据有更及时的响应。然而,大多数回归模型无法修复ITS系统中经常出现的高信噪比(SNR)或长序列丢失数据[6]。

概率模型包括基于历史数据挖掘的主成分分析(PPCA)[7]方法估计缺失的交通数据,基于张量分解的全贝叶斯生成模型[8]估计缺失数据等。贝叶斯主成分分析(BPCA)[9]结合了上面提到的这两种算法,以实现流量的周期性、局部可预测性和流量的统计特性之间的平衡。贝叶斯高斯CANDECOMP/PARAFAC张量分解(BGCP)[10]算法将张量分解扩展到将其应用于时空交通数据插值任务,解决了时空多维环境下数据归属缺失问题。变分贝叶斯(VB)[11]算法利用网络流量的时空特性来提高丢失数据恢复的质量,充分捕捉流量数据的多维时空特性。

深度学习在包括交通在内的许多领域都显示出巨大的潜力[12]。基于深度学习的数据恢复模型依赖于大规模流量数据,并更好地结合了非线性因素的影响。卷积神经网络(CNN)[13]常用于图像数据恢复和提高图像分辨率,Dong[14]等人提出的超分辨率卷积神经网络(SRCNN)能够以端到端的方式学习从低分辨率图像到高分辨率图像的恢复过程。

生成对抗网络 (GAN) [15] 是一种可以利用历史交通数据提取更多的时空特征, 提高恢复精度的交通信息恢复方法。Luo 和 Wang [16] 等推进了 GAN 在交通数据恢复方面的研究。Arora, S. [17] 对生成对抗网络 (GAN) 在不同情况下的泛化能力进行了研究。M. Arif [18] 建立了具有非参数回归的深度学习模型, 以提高非线性时空效应下丢失数据的预测。D. Tran 等 [19] 发现 3D 卷积比 2D 卷积更适合时空特征学习, 更容易训练和使用。K. Xie [20] 提出了一种顺序张量补全方法来降低高维神经网络算法的计算成本。上述研究都促进了 3D 卷积生成对抗性网络 (GAN) [21] 的应用, 它可以有效地恢复大规模交通网络中的交通数据。

综上所述, 虽然现有研究在交通数据恢复领域取得了一定的进展, 但修复大规模数据缺失的准确性仍有待提高。交通数据由多个参数组成, 例如流量、速度和占用率, 这些参数相互关联, 包含复杂的高维交通规则。

几何代数对多维信号具有很强的表达能力, 可以更好地实现高维相关性的学习。考虑到深度学习的优势, 我们:

- 提出了一种基于几何代数的生成对抗网络 (GAGAN), 其中生成器由几何代数卷积模块、注意力模块和反卷积模块组成, 判别器则由多通道卷积神经网络组成, 损失函数考虑了数据均方误差。
- 该网络通过智能计算, 学习多维交通参数的相关性来恢复丢失的交通数据, 将几何代数和生成对抗网络耦合到单个模型中, 可以提高交通数据修复的性能。
- 基于上海两条道路交通数据进行了一定的实验, 对实验结果进行了比较和分析, 结果表明该方法能够有效地修复丢失数据, 且具有较好的鲁棒性。

## 二、欧几里得三维空间中几何代数

几何代数是向量代数的推广, 它已成功应用于物理和工程领域。与经典的向量代数相比, 基于几何代数的建模能力得到了极大的扩展。由于是无坐标系, 它可以更好地捕捉问题的几何特征, 为多维信号提供更强大的表示和处理框架。

交通数据恢复问题一般在三维欧几里得空间 ( $R_3$ ) 中进行处理, 因此首先简要介绍欧氏 3D 空间 ( $R_3$ ) 的几何代数。

如等式 (1) 及图 1 所示, 3D 欧几里得空间 ( $R_3$ ) 的几何代数有 8 个基元:

$$R_3 = \text{span}\{1, e_1, e_2, e_3, e_{23}, e_{31}, e_{12}, e_{123} = I_3\} \quad (1)$$




图1 三维欧几里得空间

其中 1 为标量， $e_1$ 、 $e_2$ 和 $e_3$ 表示标准正交基向量； $e_{12}$ 、 $e_{23}$ 和 $e_{31}$ 表示单位双向量； $e_{123}$ 表示单位三向量。对于一个单位立方体， $e_1$ 、 $e_2$ 和 $e_3$ 代表 3 个轴， $e_{12}$ 、 $e_{23}$ 和 $e_{31}$ 对应 3 个面， $e_{123}$ 指示立方体。通过组合这些基本元素，可以形成表示多维向量，以高效地处理多面体。

几何乘积即几何代数的基本乘积，它是不可交换的，表达为内积和外积的组合，表 1 显示了基本元素的几何乘积的结果。

	1	$e_1$	$e_2$	$e_3$	$e_{12}$	$e_{23}$	$e_{31}$	$e_{123}$
1	1	$e_1$	$e_2$	$e_3$	$e_{12}$	$e_{23}$	$e_{31}$	$e_{123}$
$e_1$	$e_1$	1	$e_{12}$	$e_{13}$	$e_2$	$e_{123}$	$-e_3$	$e_{23}$
$e_2$	$e_2$	$-e_{12}$	1	$e_{23}$	$-e_1$	$e_3$	$-e_{123}$	$-e_{13}$
$e_3$	$e_3$	$-e_{13}$	$-e_{23}$	1	$-e_1$	$e_{123}$	$-e_2$	$e_{12}$
$e_{12}$	$e_{12}$	$-e_2$	$e_1$	$e_{123}$	$-1$	$e_{13}$	$e_{23}$	$-e_3$
$e_{23}$	$e_{23}$	$e_{123}$	$-e_3$	$e_2$	$-e_{13}$	$-1$	$-e_{12}$	$-e_1$
$e_{31}$	$e_{31}$	$e_3$	$e_{123}$	$e_1$	$-e_{23}$	$e_{12}$	$-1$	$-e_2$
$e_{123}$	$e_{123}$	$e_{23}$	$-e_{13}$	$e_{12}$	$-e_3$	$-e_1$	$-e_2$	$-1$

表 1 几何乘积结果

## 三、GAN 网络结构

生成模型是无监督学习中最为关键的技术之一，2014 年 Goodfellow 等人基于深度生成模型第一次提出了生成式对抗网络模型（GAN），与其他生成模型相比，GAN 的显著不同在于，该方法不直接以数据分布和模型分布的差异为目标函数，转而采用了对抗的方式，先通过“判别器”学习差异，再引导“生成器”去缩小这种差异，这是截至目前在深度学习领域中最新的生成模型。

GAN 的主要思想是 MIN-MAX 的零和博弈，通过“生成器”和“判别器”的对抗实现学习。训练时“生成器”和“训练器交替训练”，更新一方时，固定另一方，随着训练次数的增加，当二者达到平衡时，“判别器”输出 0.5，表示无法区分真实数据和生成数据。这一过程的优化目标是：

$$\min 1_G \max 1_D (G, D) = E_{y \sim P_{\text{data}}(y)} [\log D(y)] + E_{z \sim P_z(z)} [\log (1 - D(G(z)))]$$

以生成图像为例，“生成器”通过引入随机噪声负责生成一个与训练样本几乎一致的对象，而“判别器”则主要负责判断输入样本是否是真实的训练样本，在“生成器”与“判别器”的对抗博弈中，两者会更新各自参数，以极小化损失，即“生成器”和“判别器”的损失函数都依赖于对方的参数，但又不能直接更新对方的参数。在整个博弈的过程中，两者的性能均会上升，最后也就得到了一张生成器网络生成的逼真“伪造”图像。

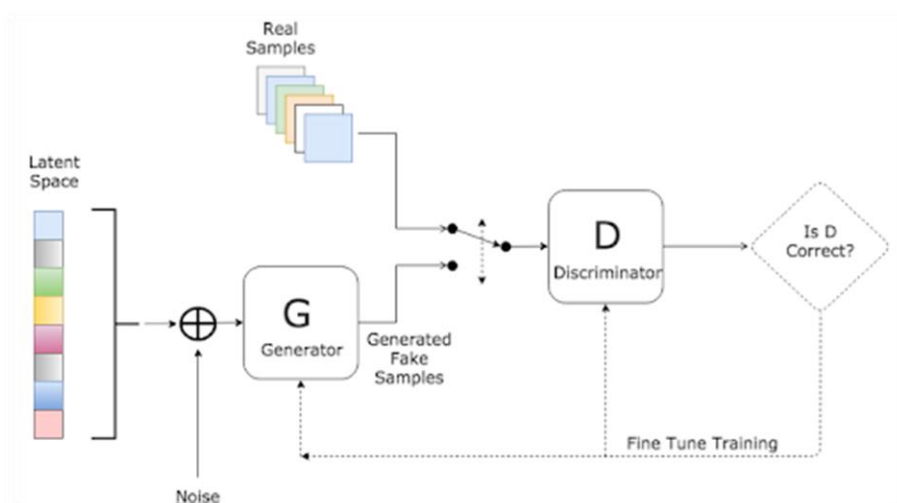


图 2 GAN 模型结构示意图

较以往的生成模型而言，GAN 优势较为明显：数据生成的复杂度与维度是线性相关的，对于较大维度的样本生成，增加神经网络的输出维度时，不会像传统模型一样面临指数级上升的计算量；其次是对数据的分布不做显性限制，避免了人工模型设计分布的需要；最后，相较于其他模型 (VAE, PixelCNN)，生成的图像更为清晰。

但是和有明确目标的深度学习问题不同，非收敛情景带来的模式坍塌阻碍了原始 GAN 模型的发展。由于 GAN 训练时并没有明确的目标函数，而是两个玩家博弈的结果，最终可能会无法达到一种均衡，而是产生震荡。另外，GAN 还存在无法生成离散语言，评价机制的设计较为困难等问题。所以在此后的发展中，主要针对 GAN 的网络结构、正则方法、算法设计及判别机制做出了更多的优化。

GAN 网络结构早期研究中发现将生成器中的全连接层用反卷积层代替，可以在图像识别方面取得更好的效果。DCGAN 就是基于以上的基本思想，采用半监督的方式，以指导数据生成过程。在此基础上，Odena 等人提出条件生成式对抗网络 (Conditional GAN, CGAN)，CGAN 中的标签一般是含有特定语义信息的已知条件，用于“生成器”的强化训练，后续他们又研究出了 ACGAN，在“判别器”的数据中也加入了类别信息，从而更好地进行模拟。




图 3 GAN 模型结构示意图

## 四、GAGAN 模型

### 3.1 总体实验架构

位于道路上的检测器以一定的时间间隔采集原始交通数据，包括速度、流量和占有率。为实现目标，即对受损交通数据的修复，对总体实验流程进行了设计，如图 2 所示。

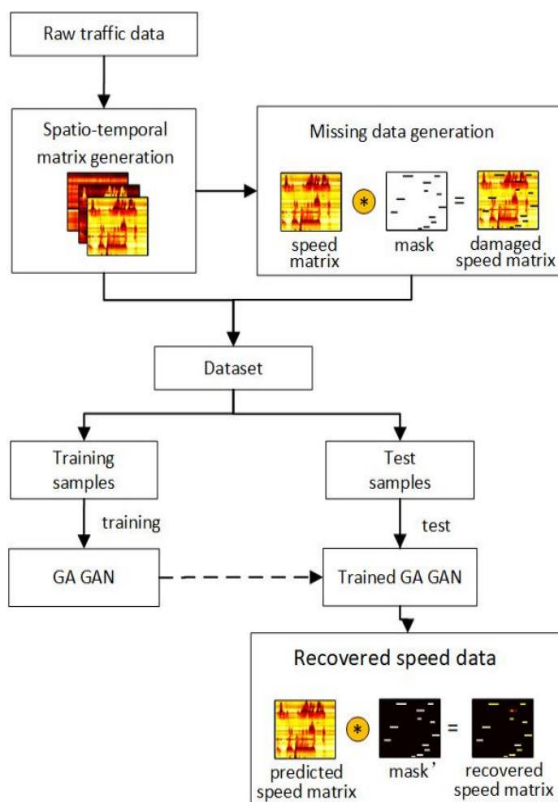


图 4 总体实验流程

首先对原始交通数据进行预处理，以生成标量时空矩阵；然后通过几何代数框架中嵌入交通数据，创集合一天特定交通参数信息的多向量时空矩阵。将包含速度信息的矩阵与随机生成的相同大小掩模逐点相乘，生成损坏的速度矩阵。损坏的速度矩阵、完全流量矩阵和完全占用矩阵沟通构为完全速度矩阵的样本。将样本随机分为训练样本和测试样本，训练样本用于训练提出的 GAGAN 模型，测试样本用于修复和测试模型的性能。

### 3.2 生成损坏数据集

#### (1) 数据归一化

交通数据由部署在道路上的探测器收集，交通参数在不同道路上的取值范围不同，因此必须进行数据归一化。



## (2) 构造交通参数时空矩阵

矩阵的行下标表示探测器的位置，列下标表示一天中的不同时间，矩阵元素为交通速度的值大小。构造出的速度时空矩阵 $S$ 表达如下：

$$S = \begin{bmatrix} s_{11} & s_{12} & \dots & s_{1n} \\ s_{21} & s_{22} & \dots & s_{2n} \\ \dots & s_{ij} & \dots & \dots \\ s_{m1} & s_{m2} & \dots & s_{mn} \end{bmatrix}$$

其中， $m$  和  $n$  分别是道路检测器的数量和时间间隔的数量， $s_{ij}$ 是第  $i$  个道路检测器在第  $j$  个时间周期的速度。

类似地，可以构造流量时空矩阵 $F$ 和占有率时空矩阵 $O$ 。

## (3) 模拟对交通速度数据的破坏

流量数据损坏的发生位置和形状都较为随机。因此，我们使用两种不同形状的掩模，对数据的不同位置进行随机破坏。一种是条形损伤，这种情况下，损伤数据是连续的，在时空矩阵中显示为矩形。另一种是离散损伤，损伤数据非连续，在时空矩阵中以点的形式表示。掩模表达式如下：

$$Mask = \begin{bmatrix} k_{11} & k_{12} & \dots & k_{1n} \\ k_{21} & k_{22} & \dots & k_{2n} \\ \dots & k_{ij} & \dots & \dots \\ k_{m1} & k_{m2} & \dots & k_{mn} \end{bmatrix}$$

其中， $k_{ij}$ 表示该点的损坏情况， $k_{ij} = 0$ 表示该点已损坏， $k_{ij} = 1$ 则保留该点数据。

最后，将速度时空矩阵和掩码逐点相乘，获得被破坏的数据集。

## 3.3 GAGAN 模型

考虑到 GAN 网络在图像生成方面的优异性能，我们以 GAN 为基础框架，做出了优化以适应更健壮的输入特征和复杂的交通环境，提出了基于几何代数卷积的 GAN 模型（GAGAN）。模型的总体架构如图 5 所示：

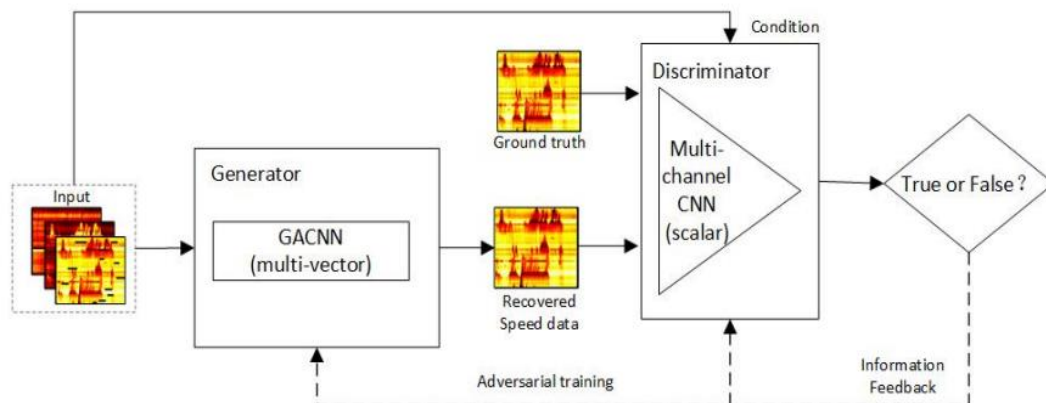


图 5 基于集合代数卷积的 GAN 模型



为了充分利用交通参数之间的相关性，使用以下三个参数：破损速度、完整流量、完整占有率作为 GAGAN 的输入。其中生成器用于提取受损的时空特征，然后使用解卷积对所获得的高维特征进行解码，以生成修复的伪图像。鉴别器的作用是判断生成器生成的结果的真假，不断向生成器反馈信息，从而提高模型的修复精度。

## (1) 生成器结构

生成器的结构如图 6 所示。它由编码和解码两部分组成。编码部分采用几何代数卷积神经网络，充分提取时空矩阵中包含的多维交通特征。解码部分利用解卷积结构对提取的交通参数的综合时空特征进行解码，然后输出与输入速度矩阵大小相同的修复速度矩阵。

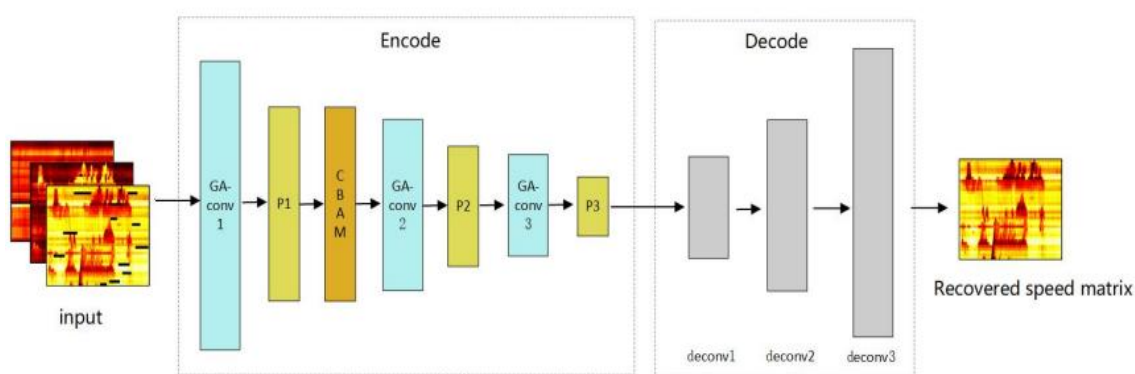


图 6 几何代数卷积 GAN 的生成器结构

在完成流量参数的高维特征提取后，需要对提取的高维特征进行解码。如上所示，我们基于三个双向量和一个标量执行特征编码。因此，当解码时，从三个双向量和一个标量的四个维度执行反卷积。通过反卷积得到的特征图对交通速度信息进行逐层解码。最后，将这四个维度得到的特征图进行融合，按照通道拼接在一起，经过最后一层反卷积层，得到恢复的交通速度矩阵。

## (2) 几何代数卷积神经网络（GACNN）

为了对高维特征进行建模，我们提出了一种几何代数卷积神经网络模型（GACNN）。它基于几何代数，弥补了现有深度神经网络通常只包含标量值神经元的局限。几何代数允许通过将多维特征集成和处理为单个实体来对输入特征组之间的潜在依赖性进行编码。所以我们用三个参数，生成使用等式描述的多向量时空矩阵，以此作为模型的输入，使得神经网络的输入神经元不再只是一个标量，而是可以表示多个交通参数信息的向量。矩阵  $Z$  表示对一天的交通信息进行编码后形成的多向量时空矩阵：

$$Z = \begin{bmatrix} z_{11} & z_{12} & \dots & z_{1n} \\ z_{21} & z_{22} & \dots & z_{2n} \\ \dots & z_{ij} & \dots & \dots \\ z_{m1} & z_{m2} & \dots & z_{mn} \end{bmatrix}$$

其中， $m$  和  $n$  分别是道路检测器的数量和时间间隔的数量， $z_{ij}$  是第  $i$  个道路检测器在第  $j$  个时间周期的三个参数的多向量，可以表示为以下形式：

$$z_{ij} = z_{ij}^r + F_{ij}e_{12} + S_{ij}e_{23} + O_{ij}e_{31}$$

根据几何代数的基元之间的几何乘积关系和分布规律，两个多向量时空矩阵  $X_g^l$  和  $W_g^l$  的几何乘积定义如下：

$$\begin{aligned} X_g^l \otimes W_g^l &= X_g^l \cdot W_g^l + X_g^l \wedge W_g^l \\ &= (X_r^l w_r^l - X_1^l w_1^l - X_2^l w_2^l - X_3^l w_3^l) + \\ &\quad (X_r^l w_1^l + X_1^l w_r^l + X_2^l w_3^l - X_3^l w_2^l)e_{12} + \\ &\quad (X_r^l w_2^l - X_1^l w_3^l + X_2^l w_r^l + X_3^l w_1^l)e_{23} + \\ &\quad (X_r^l w_3^l + X_1^l w_2^l - X_2^l w_1^l + X_3^l w_r^l)e_{31} \end{aligned}$$

在几何乘积中，我们根据维数将二维向量值神经元映射为多个标量神经元。结果矩阵的实部和虚部为分别由 4 个普通卷积的结果相加和相减得到。所以几何积运算的实现过程如图 7 所示，相当于聚合了几个独立的标准卷积结果。



图 7 几何代数卷积层的实现

几何卷积层主要基于几何代数中的几何乘积运算，实现多个向量神经元之间的信息传递。神经元之间进行局部连接，权重共享，每一层包含具有多个向量值的多个权重矩阵。因此，当第  $L$  层的第  $j$  个神经元连接到上层的第  $u$  个神经元时，相应输出可以表示为：

$$\begin{aligned} X_j^L &= f\left(\sum_{i=1}^u X_i^{L-1} \otimes W_{ij}^L + b_j^L\right) \\ &= f\left(\sum_{i=1}^u (X_i^{L-1} \cdot W_{ij}^L + X_i^{L-1} \wedge W_{ij}^L) + b_j^L\right) \end{aligned}$$

其中， $\otimes$ ,  $\cdot$ ,  $\wedge$  分别表示几何积、内积和外积。多个向量  $X_j^L$ 、 $X_i^{L-1}$ 、 $W_{ij}^L$ 、 $b_j^L$  分别代表第  $L$  层的第  $j$  个输出神经元、第  $L-1$  层的第  $i$  个输出神经元、二者之间的连接权重、第  $L$  层第  $j$  个神经元的偏置量。 $f$  代表激活函数 ReLU。

综上所述，为了使几何代数神经网络的结构易于实现，在每个几何卷积层中，我们将几何乘积的结果进行分组，得到一个实部和三个独立的虚部，然后加入偏移量和激活函数，得到的结果作为下一层的输入特征图。几何卷积层的计算类似于 3D 卷积神经网络，可以实现时空信息的联合学习，但与 3D 卷积不同的是，几何卷积层的几何乘积运算不仅可以反映高维空间的幅度特征和相关性，还可以测量和揭示不同物体之间的相对空间关系。

### (3) 卷积块注意模块 (CBAM)

距离待修复区域较远的交通区域提供的信息并不多，甚至可能干扰修复结果。因此，我们引入了卷积块注意模块 (CBAM) 来提取有用信息和过滤无用信息，从而提高特征提取能力。CBAM 层由通道注意模块和空间注意模块两部分组成，通道注意模块首先采用全局平均池化和全局最大池化。池化后得到的特征图通过全连通层和相应的激活函数对通道间的相关性进行建模。最后，将原始特征与特征通道的权重逐通道相乘，完成原始特征在通道维度上的重新校准。

通道注意模块的计算方法描述如下：

$$F_c = \sigma(MLP(AvgPool(F)) + MLP(MaxPool(F))) \odot F$$

空间注意模块将通道注意模块的输出作为输入。还使用了全局平均池和全局最大池。不同的是，池化操作将多通道特征图压缩为单个通道，使得后续的卷积只关注空间维度。最后，相同的重新校准操作是将新获得的空间维中的权重乘以特征图，以获得由双重注意力模型调整的特征图。在数学上，空间注意力模块的计算方法描述如下：

$$F_s(F_c) = \sigma(f^{7*7}(AvgPool(F_c) \oplus MaxPool(F_c))) \odot F_c$$

## (4) 鉴别器结构

为尽可能准确地区分生成器生成的修复值和真实值，我们使用具有出色优秀学习能力的 CNN 来构建鉴别器。由于生成器的输入和输出可以看作是一对，如果没有条件来控制约束鉴别器，就很难解释生成器的输出是否与输入相关。因此，为了让生成器和鉴别器做出更可靠的决策，我们将输入到生成器的 F、S、O 矩阵作为条件输入，也输入到鉴别器中。鉴别器被训练以确定该对是真还是假。鉴别器如图 8 所示，由多通道 CNN 组成，并以 F、S、O 矩阵为条件。

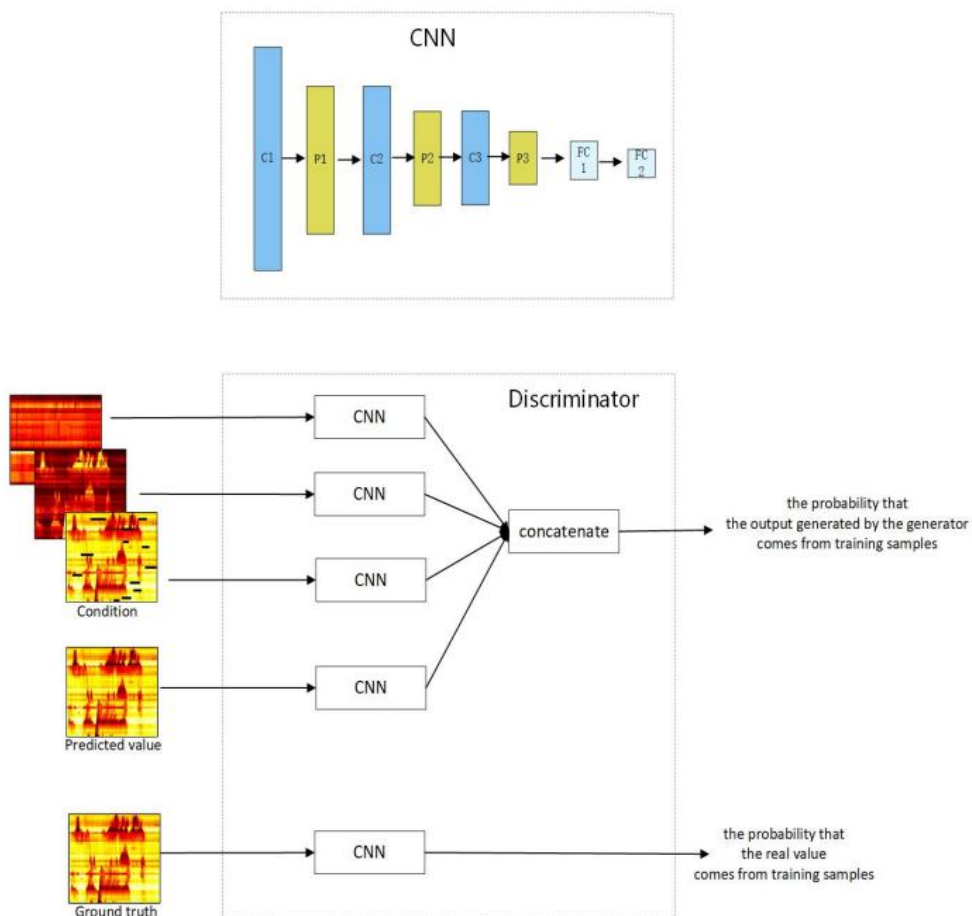


图 8 鉴别器结构

## (5) 损失函数

损失函数定义如下：

$$L = \alpha L_d + \beta L_{totalMSE} + \gamma L_{localMSE}$$

$$L_{totalMSE} = \frac{1}{N} \sum_{i=1}^N (S_i - \hat{S}_i)^2$$

$$L_{localMSE} = \frac{1}{M} \sum_{i=1}^M ((S_i - \hat{S}_i) * (\tilde{M} - Mask))^2$$

## 五、GAGAN 模型实验结果

### 5.1 数据集

本研究中采取了 2011 年在中国上海的延安和内环两条高架公路上收集的实验数据，两条道路地理位置如图 9 所示，是上海城市交通网络的重要组成部分。

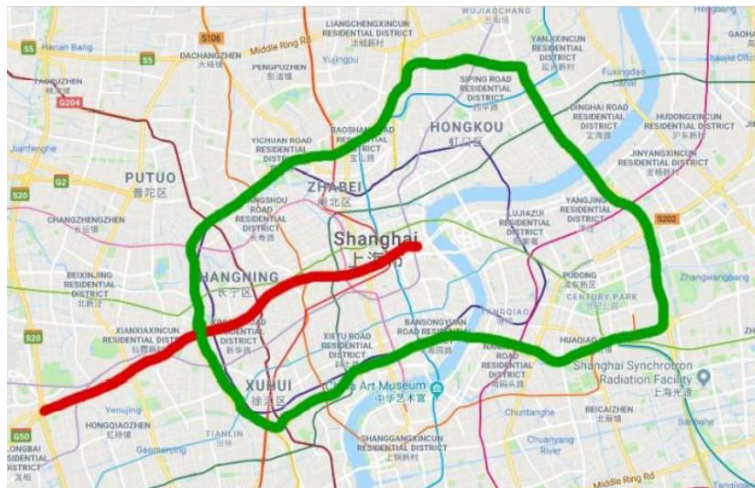


图 9 高架公路地理位置（红色粗线为延安高架，绿色粗线为内环高架）

在高架上每隔 400 米设置一个环形探测器，探测器每 5 分钟在其位置收集和存储交通数据，包括流量、速度和占有率三个数据，延安和内环高架上分别有 35 台和 72 台检测器，一天采集 288 个时间点。

损坏的速度时空矩阵、流量矩阵和占有率矩阵共同构成输入，标签为完整的速度时空矩阵。2011 年全年的所有矩阵构成了每条高架公路的基础数据集。我们随机选择 36 个样本作为每个数据集的测试集，其余样本作为训练集。延安和内环高架各包括 325 和 329 个样本。

### 5.2 实验设置

所提出的 GAGAN 模型的参数配置如表 2 和表 3 所示，两条高架公路所使用的参数和网络结构相同。所有卷积核的步长设置为  $1 \times 1$ 。生成器和鉴别器的学习率设置为 0.0001，网络总迭代次数为 10,000 次。

Layers	Name	Description
1	GA-conv Layer1	32 kernels of size $3 \times 3 \times 1$
2	Pooling1	kernels of size $2 \times 2$
3	CBAM	attention module
4	GA-conv Layer2	64 kernels of size $3 \times 3 \times 32$
5	Pooling2	kernels of size $2 \times 2$
6	GA-conv Layer3	64 kernels of size $3 \times 3 \times 64$
7	Pooling3	kernels of size $2 \times 2$
8	deconv Layer1	64 kernels of size $3 \times 3 \times 64$
9	deconv Layer2	64 kernels of size $3 \times 3 \times 32$
10	deconv Layer3	32 kernels of size $3 \times 3 \times 1$

表 2 生成器中 GACNN 参数配置



Layers	Name	Description
1	convolution1	32 kernels of size 5×5×31
2	pooling1	kernels of size 2×2
3	convolution2	64 kernels of size 3×3×32
4	pooling2	kernels of size 2×2
5	FC1	128 neuron nodes
6	FC2	1 neuron nodes

表 3 鉴别器中 CNN 参数配置

## 5.3 实验结果及分析

### (1) GAGAN 模型修复结果与与地面实况对比

为从可视化结果中直观地说明我们模型的修复性能，将速度矩阵可视化为热图，它可以直观地向我们揭示一天中交通速度的真实信息。在热图中，X 轴表示一天的时间序列，Y 轴表示探测器的数量，也反映了探测器的位置，不同颜色阴影代表不同速度值，颜色越深，速度值越小。表 4 列出了延安高架公路的数据修复结果和实际结果的对比，表 5 列出了内环高架公路的数据修复结果和实际结果的对比。

从地面实况和修复结果的热图可以直观看出，模型修复结果与地面实况非常接近。

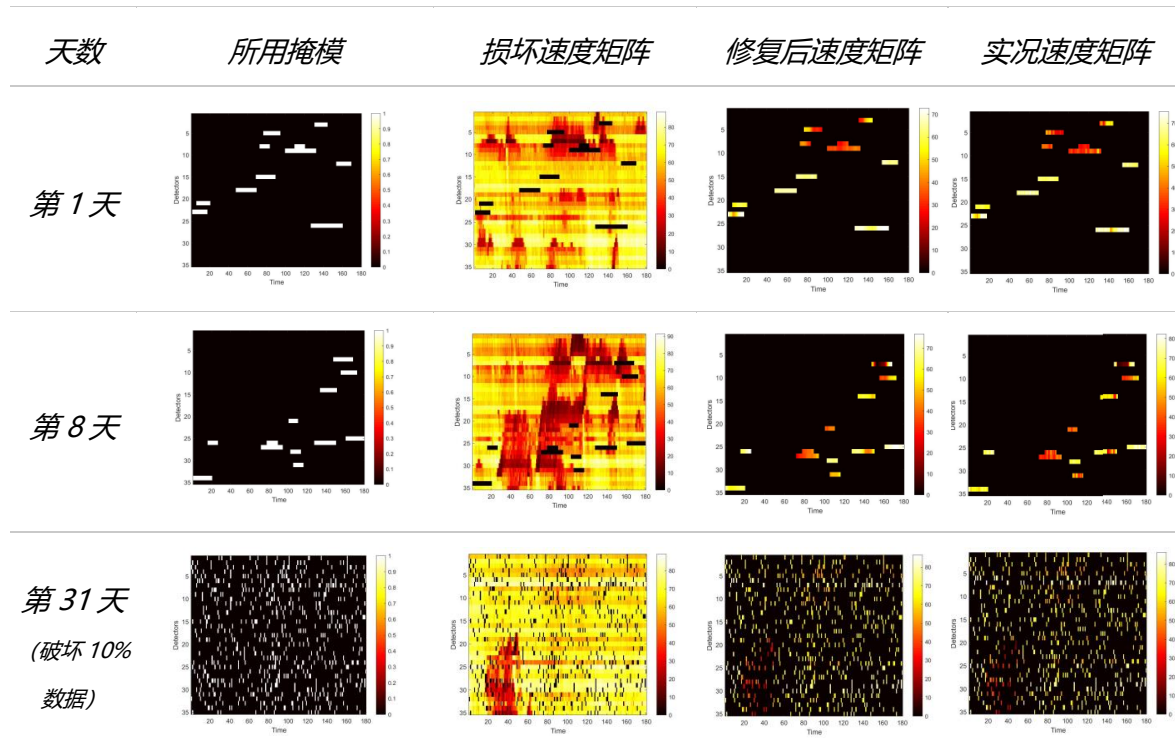


表 4 延安高架公路的数据修复结果

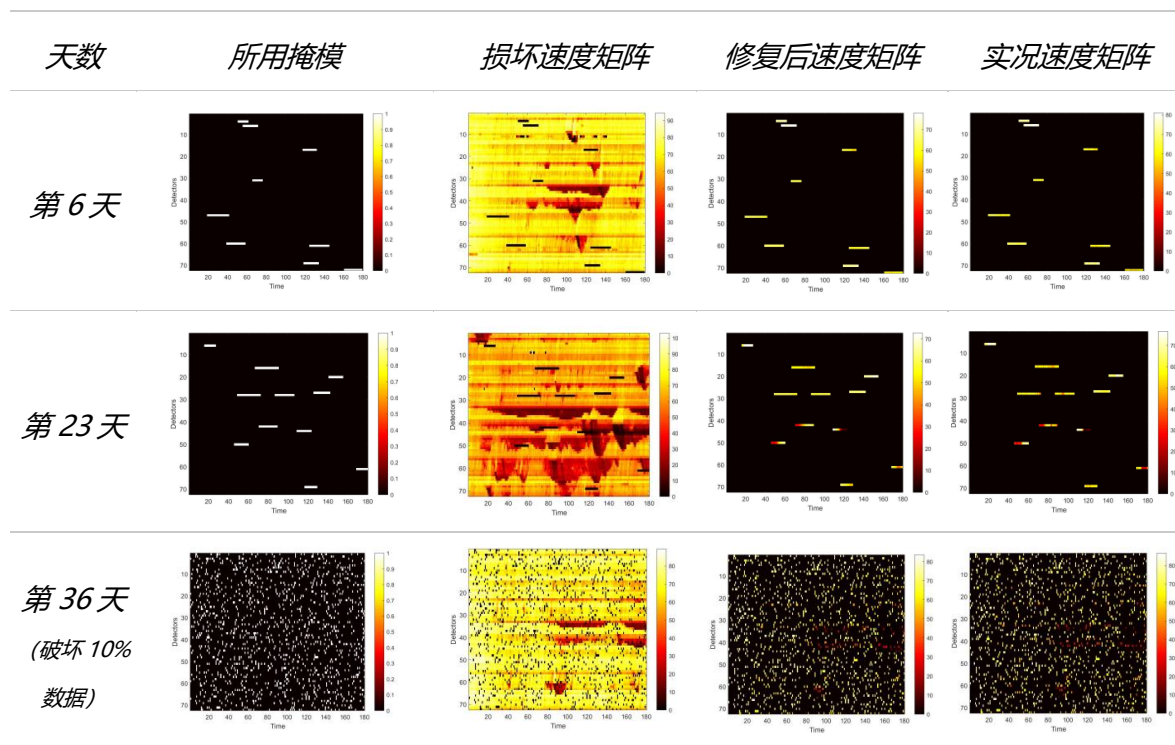


表 5 内环高架公路的数据修复结果

图 10 和图 11 分别是延安和内环高架公路的损伤值曲线和相应的地面实况曲线，图中各子图表示不同检测器在不同天所检测的数据。其中，蓝色实线表示地面实况，黄色实线表示模型的修复结果，其他不同颜色和类型的曲线表示用于比较的模型的修复结果。从这些图中可以看出，我们的模型生成的修复结果最接近真实情况。

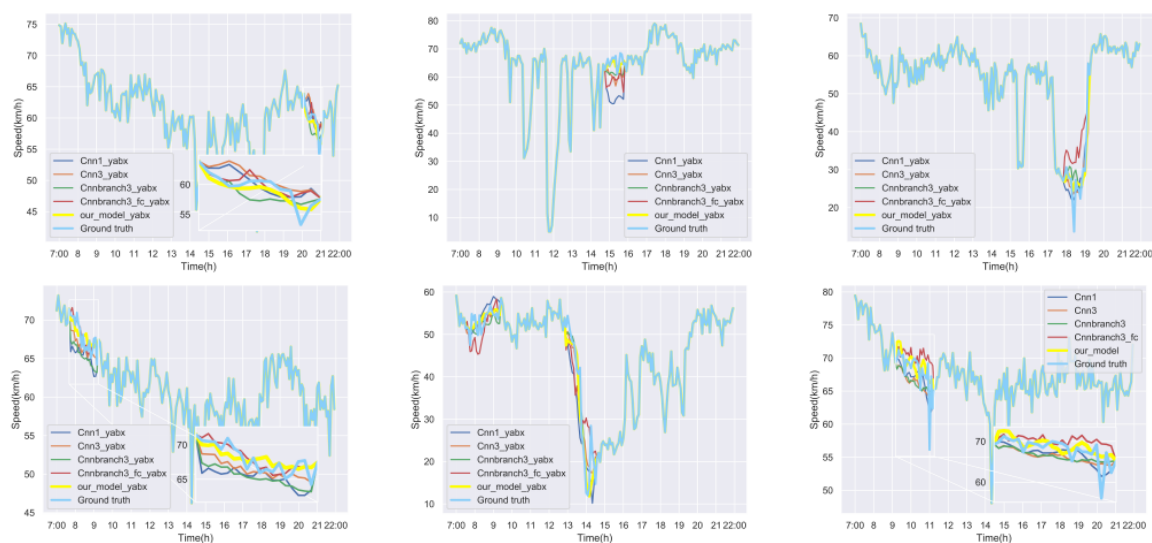


图 10 延安高架公路的数据修复结果对比



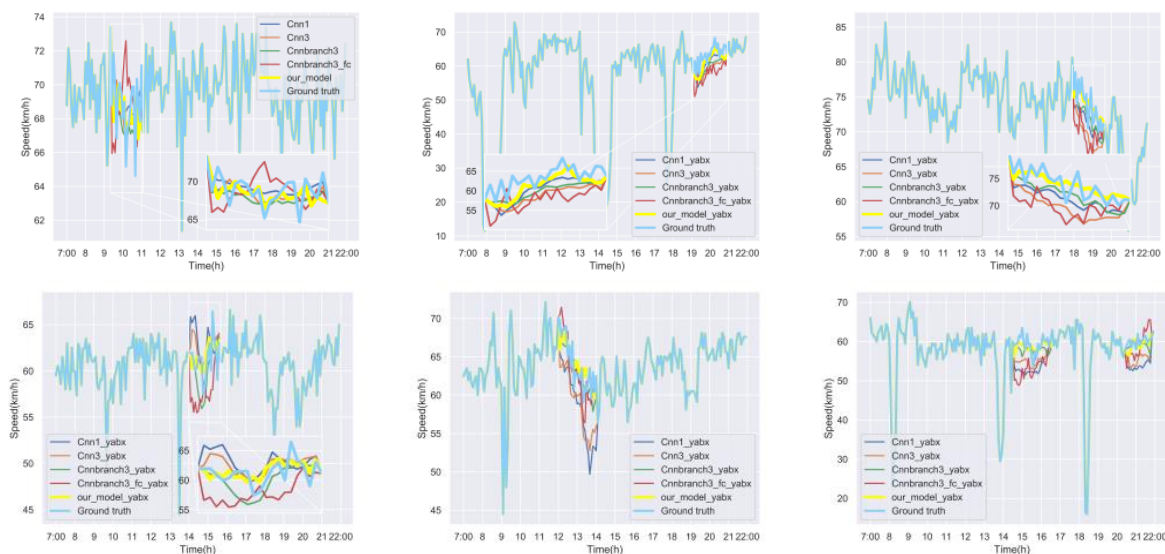


图 11 内环高架公路的数据修复结果对比

## (2) GAGAN 模型修复结果与其他模型对比

将该方法与 CNNBranch3[24]、CNN3[25]、CNN1[19]和 CNNBranch3 FC 进行比较。使用 L1 损失函数和 L2 损失函数来衡量修复的结果，L1 损失函数计算损坏位置的绝对误差，L2 损失用于最小化平方误差。

$$L_1 = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$L_2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

其中, CNNBranch3 和我们所构造的模型 GAGAN 之间的区别仅仅在于生成器的卷积层。当 GAGAN 使用几何卷积时, CNNBranch3 使用传统的标量卷积。与 CNNBranch3 使用多分支结构来处理 FS0 的三个参数的输入相比, CNN3 简单地使用三通道卷积来作为 FS0 的三个参数处理输入。为了证明参数相关性对修复效果的影响, 采用 CNN1 作为对比实验。它只使用损坏的速度参数作为输入, 而不使用流量和占有率。CNN1 也使用标量卷积。在最后的 CNNBranch3 FC 模型中, 与 CNNBranch3 模型相比, 生成器的反卷积层被替换为全连接层, 其他模块保持不变, 以证明解码高维特征的重要性。

为了进一步验证泛化能力, 在离散损伤的情况下, 进行了不同损伤程度的进一步的对比实验。受害面积占总面积的比例分别为 10%、20%、30%、40%和 50%。以两个实验评价指标的数值为纵坐标, 以损伤程度为横坐标, 得到图 12。从图中可以看出, 随着损伤程度的增加, 模型的性能也在合理的范围内下降。但我们提出的模型仍然具有最好的性能, 这证明了该模型的鲁棒性。




图 12 GAGAN 与 CNNBranch3、CNN3、CNN1 和 CNNBranch3FC 的修复结果对比

从以上结果中可以看出，与其他方法相比，本文提出的模型具有最低的误差和最佳的性能。CNN1 和 CNNBranch3 FC 表现最差。CNN1 没有考虑流量参数的相关性，导致特征不足。CNNBranch3 FC 没有有效地解码所提取的特征。CNN3 由于充分利用了参数相关和反卷积的优秀解码能力，其性能优于前两者。与 CNN3 相比，CNNBRANCH3 具有更好的性能。

## 六、结论

在本文中，我们提出了一种基于几何代数的生成对抗网络，来处理修复丢失的交通速度数据的重要任务。首先将原始交通数据（包括速度、流量和占有率）处理为时空矩阵。为了充分利用不同交通参数之间的相关性，将速度、流量和占有率数据嵌入到几何代数框架中，形成多个向量，并将其作为所提出模型的输入。生成器中的几何卷积模块对高维数据进行编码，并对多维流量参数进行高效联合学习。生成器中的去卷积模块对提取的特征进行解码，并生成恢复的交通速度矩阵。在所提出的模型中，生成器损失函数考虑了来自鉴别器的反馈信息、全局和局部交通速度数据特征。同时，基于多通道卷积网络的鉴别器使修复值更加真实。最后，使用高架公路检测器获得的交通数据来评估所提出的模型的性能，实验结果表明，该模型优于现有模型，能够有效地恢复丢失的交通速度数据，并且具有较好的鲁棒性。

## 参考文献

- [1] Du, Jinghan et al. "A deep learning method for data recovery in sensor networks using effective spatio-temporal correlation data." *Sensor Review* 39 (2019):208-217.
- [2] D. Prasad, K. Kapadni, A. Gadpal, M. Visave and K.Sultanpure, "HOG, LBP and SVM based Traffic Den-sity Estimation at Intersection," 2019 IEEE Pune Section International Conference (PuneCon), 2019, pp. 1-5, doi:10.1109/PuneCon46936.2019.9105731. A. Radford, L. Metz, and S. Chintala, 'Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks', arXiv:1511.06434 [cs], Jan. 2016, Accessed: May 20, 2021. [Online]. Available: <http://arxiv.org/abs/1511.06434>
- [3] Y. Zhang and Y. Liu, "Missing traffic flow data pre-diction using least squares support vector machines in urban arterial streets," 2009 IEEE Symposium on Computational Intelligence and Data Mining, Nashville, TN, USA, 2009, pp. 76-83, doi: 10.1109/CIDM.2009.4938632.
- [4] S. Tak, S. Woo and H. Yeo, "Data-Driven Imputation Method for Traffic Data in Sectional Units of Road Links," in *IEEE Transactions on Intelligent Transportation Systems*, vol. 17, no. 6, pp. 1762-1771, June 2016, doi: 10.1109/TITS.2016.2530312.
- [5] Manoel Castro-Neto, Young-Seon Jeong, Myong-Kee Jeong, Lee D. Han,"Online-SVR for short-term traffic flow prediction under typical and atypical traffic conditions",*Expert Systems with Applications*,Volume 36, Issue 3, Part 2,2009,Pages 6164-6173,ISSN 0957-4174,https://doi.org/10.1016/j.eswa.2008.07.069.
- [6] H. S. Zhang, Y. Zhang, and Z. H. Li, et. al., "SpatialTemporal traffic data analysis based on global data management using MAS," *IEEE Transaction on Intelligent Transportation Systems*, vol. 5, no. 4, pp. 268-275, 2004.
- [7] L. Qu, L. Li, Y. Zhang and J. Hu, "PPCA-Based Missing Data Imputation for Traffic Flow Volume: A Systematical Approach," in *IEEE Transactions on Intelligent Transportation Systems*, vol. 10, no. 3, pp. 512-522, Sept. 2009, doi: 10.1109/TITS.2009.2026312.
- [8] Q. Zhao, G. Zhou, L. Zhang, A. Cichocki and S. Amari, "Robust bayesian tensor factorization for incomplete multiway data", *CoRR*, vol. abs/1410.2386, 2014.
- [9] L. Qu, Y. Zhang, J. Hu, L. Jia and L. Li, "A BPCA based missing value imputing method for traffic flow volume data", *Proc. IEEE Int. Vehicles Symp. (IV)*, pp. 985-990, Jun. 2008.
- [10] X. Chen, Z. He and L. Sun, "A Bayesian tensor decomposition approach for spatiotemporal traffic data imputation", *Transp. Res. Pt. C-Emerg. Technol.*, vol. 98,pp. 73-84, 2019.
- [11] H. Zhou, D. Zhang, K. Xie and Y. Chen, "Robust Spatiotemporal Tensor Recovery for Internet Traffic Data," 2016 IEEE Trustcom/BigDataSE/ISPA, 2016, pp. 1404-1411, doi: 10.1109/TrustCom.2016.0221.
- [12] Liang, Xiaoyuan. "Applied deep learning in intelligent transportation systems and embedding exploration." (2019).

- [13] C. Dong, C. C. Loy, K. He and X. Tang, "Image SuperResolution Using Deep Convolutional Networks," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 38, no. 2, pp. 295-307, 1 Feb. 2016, doi:10.1109/TPAMI.2015.2439281.
- [14] C. Dong, C. C. Loy, K. He and X. Tang, "Image SuperResolution Using Deep Convolutional Networks," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 38, no. 2, pp. 295-307, 1 Feb. 2016, doi:10.1109/TPAMI.2015.2439281.
- [15] K. D. B. Mudavathu, M. V. P. C. S. Rao and K.V. Ramana, "Auxiliary Conditional Generative Adversarial Networks for Image Data Set Augmentation," 2018 3rd International Conference on Inventive Computation Technologies (ICICT), 2018, pp. 263-269, doi: 10.1109/ICICT43934.2018.9034368.
- [16] M. He, X. Luo, Z. Wang, F. Yang, H. Qian and C. Hua, "Global Traffic State Recovery VIA Local Observations with Generative Adversarial Networks," ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Barcelona, Spain, 2020, pp. 3767-3771, doi:10.1109/ICASSP40776.2020.9054656.
- [17] Arora, S., Ge, R., Liang, Y., Ma, T. Zhang, Y. (2017). Generalization and Equilibrium in Generative Adversarial Nets (GANs). Proceedings of the 34th International Conference on Machine Learning, in Proceedings of Machine Learning Research 70:224-232 Available from <http://proceedings.mlr.press/v70/arora17a.html>.
- [18] M. Arif, G. Wang and S. Chen, "Deep Learning with Non-parametric Regression Model for Traffic Flow Prediction," 2018 IEEE 16th Intl Conf on Dependable, Autonomic and Secure Computing, 16th Intl Conf on Pervasive Intelligence and Computing, 4th Intl Conf on Big Data Intelligence and Computing and Cyber Science and Technology Congress(DASC/PiCom/DataCom/CyberSciTech), Athens, Greece, 2018, pp. 681-688, doi: 10.1109/DASC/PiCom/DataCom/CyberSciTec.2018.00120.
- [19] D. Tran, L. Bourdev, R. Fergus, L. Torresani and M. Paluri, "Learning Spatiotemporal Features with 3D Convolutional Networks," 2015 IEEE International Conference on Computer Vision (ICCV), 2015, pp. 4489-4497, doi: 10.1109/ICCV.2015.510.
- [20] K. Xie et al., "Accurate Recovery of Internet Traffic Data: A Sequential Tensor Completion Approach," in IEEE/ACM Transactions on Networking, vol. 26, no. 2, pp. 793-806, April 2018, doi:10.1109/TNET.2018.2797094.
- [21] Bin Ran, Huachun Tan, Yuankai Wu and Peter J. Jin, "Tensor based missing traffic data completion with spatial-temporal correlation", Physica A: Stat. Mech. and its Applicat., vol. 446, pp. 54-63, Mar. 2016.